


🏠 Architecture Lyra V2 RAG

Assistant Vocal DevOps Local - 100% Offline

! Flux de haut en bas : Entrée utilisateur → Traitement → Sortie utilisateur !



🎨 Légende des Couleurs



Utilisateur
Entrée/Sortie
(INPUT/OUTPUT)



Interface
Modes Vocal/Texte



Audio
Whisper STT + Piper
TTS



Classification
IntentClassifier
(demande/info)



RAG Pipeline
ChromaDB + BM25 +
TOON



Backend
EPHAISTOS (Qwen 7B)



Exécution
HESTIA + Confirmation



MCP Servers
80 outils (5 serveurs)



Frontend
LYRA (Llama 3B)

Flux de Traitement

1 Entrée Utilisateur (haut)

USER INPUT → Mode Vocal/Texte → Whisper STT (si vocal) → IntentClassifier

2 Classification & Routage

- 🕒 demande (action MCP) → Pipeline RAG → EPHAISTOS → MCP
- 🕒 info/discussion → LYRA directement (pas de RAG)

3 Pipeline RAG (si demande)

Query Processing → ChromaDB + BM25 → RRF Fusion → TOON Encoder → EPHAISTOS

4 Exécution MCP

EPHAISTOS → HESTIA → Confirmation (si mode default) → MCP Servers → Résultats

5 Formatage & Sortie (bas)

Résultats → Session Memory → LYRA Frontend → Piper TTS (si vocal) → **USER OUTPUT**

VRAM Allocation (RTX 3080 Ti 12GB)

Composant	Modèle	VRAM	Rôle
EPHAISTOS	Qwen 2.5 Coder 7B	~5 GB	Analyse specs MCP, extraction args
LYRA	Llama 3.2 3B	~2.5 GB	Dialogue, classification, personnalité
Embeddings	paraphrase-multilingual-MiniLM-L12-v2	~0.5 GB	Recherche sémantique RAG
Whisper	faster-whisper base (CUDA)	~1.5 GB	Speech-to-Text (mode vocal)
TOTAL		~10.5 GB	87.5% de 12 GB

MCP Servers (80 outils)

Serveur	Outils	Description	Technologie
FEDORA	17	VM KVM + Backups (vm_start, vm_clone, backup_create...)	Node.js
HUE	24	Lumières Philips Hue (turn_on/off, set_brightness...)	Python (hue-mcp)
TV	14	TV Philips 55OLED705 (power, volume, ambilight...)	Python (pylips-mcp)
CATT	15	Cast YouTube/Video (cast_youtube, cast_pause...)	Python (catt-mcp)
DENON	10	Home Cinema Denon AVR-X1700H (volume, mute, input...)	Python (denon-mcp)

Optimisations Clés

- TOON Encoder:** Compression ~40% des specs MCP avant EPHAISTOS
- BM25 Keyword:** Recherche par mots-clés français (meilleure que semantic seul)
- RRF Fusion:** Combine semantic + keyword (k=60, top_k=5)
- Pre-filtrage catégorie:** Boost résultats par mots-clés (lumière → hue, vm → fedora...)
- Mode Performance:** Skip confirmation pour domotique (TV, Hue, Denon, CATT)
- Session Memory:** Contexte multi-tour (max_turns=10) + PendingChoice
- Async Operations:** n8n webhooks + fallback subprocess (vm_clone, backup_*)